

งานวิจัยการพยากรณ์/ทำนายค่าฝุ่น PM2.5 ในประเทศไทยด้วยแบบจำลองหลายตัวแปร (Multivariate Models)

TL;DR

- มีงานวิจัยไทยจำนวนมากที่พยากรณ์/ทำนาย PM2.5 โดยใช้หลายปัจจัยนำเข้า ไม่ใช่แค่ค่า PM2.5 ย้อนหลัง โดยงานกระจุกตัวหนาแน่นที่ภาคเหนือ (เชียงใหม่/ภาคเหนือตอนบน) และกรุงเทพฯ/ปริมณฑล มีงานระดับประเทศและภาคใต้บ้าง แต่ภาคอีสานยังเป็นช่องว่าง — แทบไม่มีงานพยากรณ์ multivariate ML/DL ที่สร้างและฝึกเฉพาะเมืองอีสาน
- ปัจจัยที่นิยมใช้ได้แก่ ข้อมูลอุตุนิยมวิทยา (อุณหภูมิ ความชื้นสัมพัทธ์ ลม ฝน ความกดอากาศ) มลพิษอื่น (PM10, NO2, SO2, CO, O3) จุดความร้อน/ไฟ (MODIS/VIIRS hotspots) ค่า AOD จากดาวเทียม (Himawari-8, Fengyun-4A, MODIS MAIAC) การใช้ที่ดิน/พืชพรรณ (NDVI) ความหนาแน่นประชากร และปัจจัยเชิงเวลา (cyclical encoding, moving average)
- โมเดลเด่น คือ Random Forest / Gradient Boosting / XGBoost / LightGBM สำหรับข้อมูลตาราง และ LSTM / CNN-LSTM / ConvLSTM / SimVP-IAM4VP (video prediction) สำหรับ spatiotemporal โดยแหล่งข้อมูลหลักคือ Pollution Control Department (PCD)/Air4Thai, กรมอุตุนิยมวิทยา (TMD), Sensor for All (จุฬาฯ), ERA5/MERRA-2 และดาวเทียม

Key Findings

1. งานภาคเหนือครบถ้วนที่สุดเรื่องปัจจัยนำเข้า — Kawichai et al. (2025, *Toxics*) ใช้ 12 ตัวแปรรวมจุดความร้อน และ Sabkam (2025, *EASR*) แสดงว่าการเพิ่มข้อมูลจุดความร้อนช่วยเพิ่มความแม่นยำราว 20%
2. งานกรุงเทพฯ เน้นทั้งการพยากรณ์ล่วงหน้า (RF/GB/LSTM) และการประเมินเชิงพื้นที่ (spatiotemporal estimation) ด้วย AOD จากดาวเทียม + อุตุนิยมวิทยา + การใช้ที่ดิน
3. งานระดับประเทศ ใช้ deep learning เชิงภาพ (SimVP, ConvLSTM, IAM4VP) รวมจุดความร้อนและลมเป็นปัจจัย
4. ภาคใต้ (หาดใหญ่) มีงานใหม่ใช้ ConvLSTM1D-BiLSTM และ ARIMA-ANN-quantile
5. ภาคอีสานมีช่องว่างงานวิจัยชัดเจน — ตัวเองก็เป็นข้อค้นพบที่อ้างอิงได้: อีสานถูกศึกษาน้อยกว่าภาคเหนือและภาคกลางมาก
6. มีงานเปรียบเทียบ univariate กับ multivariate และงานที่ใช้ชุดข้อมูลไทยเปิด (Sensor for All, PCD/Air4Thai)

Details

ก) ภาคเหนือ / เชียงใหม่ / ภาคเหนือตอนบน

1. Kawichai, Sripan, Rerkasem, Rerkasem, Srisukkham (2025) — "Long-Term Retrospective Predicted Concentration of PM2.5 in Upper Northern Thailand Using Machine Learning Models", *Toxics* 13(3):170. DOI: 10.3390/toxics13030170

- พื้นที่: 8 จังหวัดภาคเหนือตอนบน (เชียงใหม่ ลำปาง เชียงราย ลำพูน พะเยาแพร่ น่าน แม่ฮ่องสอน)

- ปัจจัยนำเข้า 12 ตัว: PM10, CO2, SO2, NO2, O3, จุดความร้อน (fire hotspots), ความกดอากาศ, ฝน, ความชื้นสัมพัทธ์, อุณหภูมิ, ทิศทางลม, ความเร็วลม
- แหล่งข้อมูล: PCD (1 ม.ค. 2011 – 31 ธ.ค. 2020)
- โมเดล: MLP, SVM, MLR, Decision Tree, Random Forest (nih)
- ผล: Random Forest ดีที่สุด RMSE = $6.82 \mu\text{g}/\text{m}^3$ (nih) (ประเมินด้วย RMSE, MPE, RPE, R^2)

2. Sabkam (2025) — "Ensemble machine learning-based PM2.5 modeling using hotspot counts (0-1000 km) reflecting Chiang Mai, Thailand's extreme pollution", *Engineering and Applied Science Research* (EASR) Vol. 52 No. 5 (2025), หน้า 473-489, ISSN 2539-6218 (ตีพิมพ์ออนไลน์ 19 ส.ค. 2025); ผู้แต่งจาก Department of Electrical Engineering, North-Chiang Mai University

- พื้นที่: เชียงใหม่ (ช่วงที่ถูกจัดเป็นเมืองมลพิษสูงสุดของโลก)
- ปัจจัยนำเข้า 5 ตัวหลัก (คัดด้วย Lasso): (TCI) PM2.5 lag 1, จำนวนจุดความร้อนในระยะ 100 กม. (lag 1-3), 200/400 กม. (lag 2-4), และ >700 กม. (lag 5)
- โมเดล: Random Forest, Gradient Boosting, XGBoost, LSTM
- ผล: Gradient Boosting ชนะทุกโมเดล — $R^2 = 0.97$, RMSE = 5.49, MAE = 2.08, MAPE = 5.8% และ "Incorporating hotspot data improved model performance by approximately 20%"
- จุดเด่น: ระบุว่า "the cumulative effects of hotspots extend their influence on air quality in Chiang Mai up to approximately 700 km" (อิทธิพลสะสมของจุดความร้อนขยายไปไกลราว 700 กม.)

3. Amnuaylojaroen (2022) — "Prediction of PM2.5 in an Urban Area of Northern Thailand Using Multivariate Linear Regression Model", *Advances in Meteorology* 2022:3190484. DOI: 10.1155/2022/3190484

- พื้นที่: เชียงใหม่ ลำปาง น่าน (Wiley Online Library)
- ปัจจัยนำเข้า: AOD, อุณหภูมิ, ความชื้นสัมพัทธ์, ความเร็วลม (โมเดล 1); เพิ่ม SO2, NO2, CO, O3 (โมเดล 2)
- โมเดล: Multivariate Linear Regression; ข้อมูลรายชั่วโมงปี 2020 (Wiley Online Library)
- เป็นงานอ้างอิงพื้นฐานที่งานไทยอื่นๆ อ้างถึงบ่อย (พบ CO สัมพันธ์กับ PM2.5 สูง)

4. Wongrin, Chaisee, Suphawan (2023) — "Comparison of Statistical and Deep Learning Methods for Forecasting PM2.5 Concentration in Northern Thailand", *Polish Journal of Environmental Studies* 32(2):1419-1431. DOI: 10.15244/pjoes/157072 (Department of Statistics, Chiang Mai University)

- พื้นที่: 16 สถานีภาคเหนือ (ม.ค. 2018 – ธ.ค. 2020, PCD; 3,468 ข้อมูล)
- โมเดล: ETS (Holt-Winters), ARIMA, DLM (สถิติ) กับ RNN, LSTM (deep learning); พยากรณ์ 7 วันล่วงหน้า
- ผล: วิธีสถิติ (โดยเฉพาะ ARIMA) ให้ RMSE ต่ำกว่า deep learning (R^2 อยู่ในช่วงราว 0.50-0.94)

- หมายเหตุ: งานนี้เน้น time-series ของ PM2.5 เป็นหลัก (จัดว่าเป็นงานเปรียบเทียบเชิงวิธีมากกว่า multivariate feature)

5. Thongrod, Lim, Ingviya, Owusu (2022) — "Prediction of PM2.5 and PM10 in Chiang Mai Province: A Comparison of Machine Learning Models", *ITC-CSCC 2022 (IEEE)*. DOI: 10.1109/ITC-CSCC55581.2022.9894884

- พื้นที่: เชียงใหม่ (2012–2021) ([IEEE Xplore](#))
- โมเดล: SVM, ANN, MLR; ประเมินด้วย RMSE, MAE, MAPE; วิเคราะห์แนวโน้ม/ฤดูกาล (PM2.5/PM10 สูงสุดเดือนมีนาคม)

6. Paluang, Thavorntam, Phairuang (2024) — "Application of Multilayer Perceptron Artificial Neural Network (MLP-ANN) Algorithm for PM2.5 Mass Concentration Estimation during Open Biomass Burning Episodes in Thailand", *International Journal of Geoinformatics* 20(7):28–42. DOI: 10.52939/ijg.v20i7.3401

- พื้นที่: ฝึกจากภาคเหนือ (17 จังหวัด) แล้วนำไปประยุกต์กับ **ขอนแก่น นครราชสีมา อุบลราชธานี (ภาคอีสาน)**
- ปัจจัยนำเข้า 8 ตัว: อุณหภูมิสูงสุด, อุณหภูมิต่ำสุด, ความชื้นสัมพัทธ์, ความกดอากาศ, ความเร็วลม, การเผาชีวมวลกลางแจ้ง (Open Biomass Burning emissions — ไฟป่า + การเผาเศษวัสดุข้าว/ข้าวโพด/อ้อย), AOD (MODIS MCD19A2 MAIAC 1 กม.)
- แหล่งข้อมูล: PCD, TMD (ศูนย์อุตุฯ ภาคเหนือ/อีสาน), MODIS ผ่าน Google Earth Engine, กรมพัฒนาที่ดิน
- โมเดล: MLP-ANN สถาปัตยกรรม 8-16-1; $r = 0.7787$, $MAE = 0.0187$, $RMSE = 0.0282$ (ค่า normalized); ผลอีสาน: ขอนแก่นประเมิน 20.43 vs วัดจริง 20.48 $\mu\text{g}/\text{m}^3$
- หมายเหตุ: เป็น estimation/mapping เชิงพื้นที่ ไม่ใช้การพยากรณ์ล่วงหน้า

7. Damkliang & Chumnaul (2025 อ้างอิงเลขเล่ม 2026) — "Decoding urban PM2.5 dynamics and air pollution-health relationships using machine learning: Evidence from Northern Thailand", *Air Quality, Atmosphere & Health*. DOI: 10.1007/s11869-026-02074-6

- พื้นที่: จังหวัดแพร่ (2020–2023) ([Springer](#))
- ปัจจัย: มลพิษรายวัน + อุตุนิยมวิทยา (PM2.5 สัมพันธ์บวกกับ NO2, O3 และสัมพันธ์ลบกับความชื้นสัมพัทธ์)
- โมเดล: Random Forest Regression (RFR) และ LSTM; ([Springer](#)) ผล "The best predictive model for PM2.5 concentrations and respiratory illness cases was RFR" — เสนอใช้ RFR สำหรับพยากรณ์ปกติ และ LSTM สำหรับเตือนภัยช่วงพีด

ข) กรุงเทพฯ และปริมณฑล (Greater Bangkok)

8. Machine learning-enhanced air quality forecasting (Bangkok 2020–2024) — "Machine learning-enhanced air quality forecasting and trend analysis: A five-year comprehensive assessment of PM2.5 concentrations in Bangkok, Thailand", *ScienceDirect* (PII S2667010026000375)

- พื้นที่: 12 สถานีในกรุงเทพฯ ([ScienceDirect](#)) (ข้อมูล 2020–2024)

- **ปัจจัย:** PM2.5 + อุณหภูมิ, ฝน, ความเร็วลม, ความกดอากาศ, ความชื้นสัมพัทธ์ + feature engineering (temporal lags, moving averages, cyclical encoding) (ScienceDirect)
- **โมเดล:** Random Forest, Gradient Boosting, LSTM (ScienceDirect)
- **ผล:** Gradient Boosting ดีที่สุด — RMSE = 2.17 $\mu\text{g}/\text{m}^3$, $R^2 = 0.935$ (external validation ปี 2024, 365 วัน); RF RMSE = 3.34, $R^2 = 0.845$
- feature importance: 3-day moving average ของ PM2.5 สำคัญสุด (42.17% ใน RF)

9. Aman et al. (2025) — "Machine learning-based quantification and separation of emissions and meteorological effects on PM2.5 in Greater Bangkok", *Scientific Reports* 15. DOI: 10.1038/s41598-025-99094-6

- **พื้นที่:** Greater Bangkok (ฤดูแล้ง 2018–2022)
- **ปัจจัย:** อุตุณิยมวิทยา (ERA5/ERA5_LAND) + fire activity + land use + ข้อมูลเศรษฐกิจสังคม + AOD (Himawari-8)
- **โมเดล:** RF, AdaBoost, GB, XGBoost, LightGBM, CatBoost; **LightGBM ดีที่สุด** — รายชั่วโมง $\rho=0.9$, MAE=5.5, RMSE=8.7; รายวัน $\rho=0.95$, MAE=3.3, RMSE=4.9 $\mu\text{g}/\text{m}^3$
- ใช้ SHAP + meteorological normalization (Nature) แยก PM2.5_emis กับ PM2.5_met (งาน SHAP-normalization ครั้งแรกใน GBK)

10. Bensalam, Musikasuwat, Saelim (2025) — "Predictive models of PM2.5 concentration with aerosol optical depth and meteorological data in Bangkok area using machine learning techniques", *Science, Engineering and Health Studies* 19:25020001. DOI: 10.69598/sehs.19.25020001 (Prince of Songkla University)

- **พื้นที่:** 2 สถานีในกรุงเทพฯ (tci-thaijo)
- **ปัจจัย:** AOD + อุตุณิยมวิทยา + NO2, SO2, CO, O3 (tci-thaijo) (ระบุชัดว่าการเพิ่มก๊าซมลพิษช่วยเพิ่มความแม่นยำอย่างมีนัยสำคัญ)
- **โมเดล:** MLR, RF, SVM; SVM ดีที่สุดสำหรับสถานี ambient (tci-thaijo)

11. Spatiotemporal estimation Greater Bangkok (Himawari-8) — "Spatiotemporal analysis of PM2.5 estimated using machine learning over Greater Bangkok: Variability, trends, and persistence" (Research Square rs-3912524)

- **ปัจจัย:** AOD จาก Himawari-8, อุตุณิยมวิทยา ERA5_LAND/ERA5, fire count + NDVI จาก MODIS, ความหนาแน่นประชากรจาก WorldPop, ความสูงภูมิประเทศจาก USGS
- **โมเดล:** RF, ADB, GB, XGB, LGB, CB (Research Square) + stacked ensemble (SEM); LightGBM ดีที่สุดในกลุ่ม และ SEM เหนือกว่าทุกโมเดลเดี่ยว

12. Fengyun-4A study — "Spatiotemporal estimation of hourly PM2.5 using AOD derived from geostationary satellite Fengyun-4A and machine learning models for Greater Bangkok", *Air Quality, Atmosphere & Health*. DOI: 10.1007/s11869-024-01524-3

- **ปัจจัย:** AOD (Fengyun-4A) + อุตุณิยมวิทยา + fire hotspots + vegetation index + ความสูง + ความหนาแน่นประชากร
- **โมเดล:** RF, ADB, GB, XGB + SEM; ADB $r=0.75$, MB=0.55, ME=9.1, RMSE=12.9 $\mu\text{g}/\text{m}^3$

13. Thongthammachart, Shimadera, Araki, Matsuo, Kondo (2023) — "Land use regression model established using Light Gradient Boosting Machine incorporating the WRF/CMAQ model for highly accurate spatiotemporal PM2.5 estimation in the central region of Thailand", *Atmospheric Environment* 297:119595. DOI: 10.1016/j.atmosenv.2023.119595

- พื้นที่: ภาคกลางของไทย (รวมกรุงเทพฯ), รายวัน กริด 1 กม. (ScienceDirect)
- ปัจจัย: PM2.5 จำลองจาก CMAQ (ตัวแปรสำคัญสุดจาก SHAP), อุตุณิยมวิทยาจาก WRF, การใช้ที่ดิน, ความหนาแน่นประชากร
- โมเดล: Land Use Regression + LightGBM (เทียบ XGBoost, RF); $CV-R^2 = 0.71$ (เป็นการใช้ LUR+LightGBM+WRF/CMAQ ครั้งแรกในเอเชียตะวันออกเฉียงใต้)
- หมายเหตุ: งานปี 2021 และ 2022 ของกลุ่มเดียวกันเป็นพื้นที่ Kansai ประเทศญี่ปุ่น (อย่าสับสน)

ค) ระดับประเทศ (Nationwide / Spatiotemporal Deep Learning)

14. Sirisumpun, Wongwailikhit, Painmanakul, Vateekul (2023) — "Spatio-Temporal PM2.5 Forecasting in Thailand Using Encoder-Decoder Networks", *IEEE Access* 11:69601-69613. DOI: 10.1109/ACCESS.2023.3293398 (จุฬาลงกรณ์มหาวิทยาลัย)

- พื้นที่: ทั่วประเทศไทย (image-like / grid approach)
- ปัจจัย: PM2.5, จุดความร้อน, ลม
- โมเดล: SimVP-CFLL-ML (video prediction + cross-feature learning layer + masking layer)
- ข้อมูล: 213 สถานี PCD + 501 sensor (Sensor for All); $MAE = 4.51$, $RMSE = 7.9$, $macro F1 = 0.6557$
- มิวทิยานิพนธ์ไทยที่เกี่ยวข้อง: "การทำนายค่าฝุ่น PM2.5 ทั้งในเชิงแผนที่และเชิงเวลาด้วยเทคนิคการเรียนรู้เชิงลึก" (digital.car.chula.ac.th/chulaetd/6571)

15. Enhancing PM2.5 Forecasting Using Video-Based Spatiotemporal Models and Cyclical Encoding (ACIIDS 2025) — Springer CCIS. DOI: 10.1007/978-981-96-5884-8_26

- ปัจจัย: PM2.5, จำนวนจุดความร้อนบนพื้นผิวโลก, ลม (eastward/northward) + cyclical encoding เพื่อจับรอบรายชั่วโมง
- โมเดล: IAM4VP (video prediction); ลด MAE 13.63% และเพิ่ม F1 score 15.27% เทียบ ConvLSTM baseline
- ข้อมูล: Sensor for All + PCD (2022-2023) (Springer)

16. Kaewbundit, Churngam, Wongchaisuwat (2025) — "A spatiotemporal deep learning ensemble for multi-step PM2.5 prediction: A case study of Bangkok metropolitan region in Thailand", *Atmospheric Pollution Research* Vol. 16 (2025), PII S130910422500008X (มหาวิทยาลัยเกษตรศาสตร์)

- พื้นที่: Bangkok metropolitan region (แปลงข้อมูลสถานีเป็น grid)
- ปัจจัย: AOD ดาวเทียม, อุตุณิยมวิทยา, การใช้ที่ดิน (external inputs)

- โมเดล: **ensemble** ของ **recurrent (ConvLSTM, SwinLSTM) + recurrent-free (SimVP, MogaNet)**; พยากรณ์ 6, 12, 24 ชม.ล่วงหน้า ([ScienceDirect](#))
- ข้อสรุป: ข้อมูลดาวเทียมช่วยเพิ่มความแม่นยำอย่างมาก และ ensemble เหนือกว่าโมเดลเดี่ยว

17. Buya, Usanavasin, Gokon, Karnjana (2023) — "An Estimation of Daily PM2.5 Concentration in Thailand Using Satellite Data at 1-Kilometer Resolution", *Sustainability* 15(13):10024. DOI: 10.3390/su151310024

- พื้นที่: ทั่วประเทศไทย, กริด ([Preprints.org](#)) 1 กม. ([MDPI](#))
- ปัจจัย: AOD (Multi-MAIAC), LST (อุณหภูมิพื้นผิว), NDVI, Elevation, Week of year, year
- โมเดล: MLR, RF, XGBoost, SVM; **RF ดีที่สุด — training $R^2=0.95$ /RMSE=5.58; validation $R^2=0.78$ /RMSE=11.18; test $R^2=0.71$ /RMSE=8.79 $\mu\text{g}/\text{m}^3$**
- เป็นชุดข้อมูล/โมเดลที่งานสุขภาพไทยอื่นนำไปใช้ต่อ

ง) ภาคใต้ (หาดใหญ่/สงขลา)

18. Chumnaul (2025) — "Deep learning and statistical approaches for area-based PM2.5 forecasting in Hat Yai, Thailand", *Journal of Big Data* 12(1):36. DOI: 10.1186/s40537-025-01079-9 (Prince of Songkla University)

- พื้นที่: หาดใหญ่ สงขลา (ข้อมูลรายวัน 2013–2023)
- โมเดล: **ConvLSTM1D-BiLSTM** (window 7-input/1-output/6 strides); MAE = 2.05, $R^2 = 0.68$; ผลพยากรณ์ 7 วัน RMSE=4.004, MAE=3.444, MAPE=16.595; ([Springer](#)) external validation 4 สถานีใกล้เคียง MAE=1.38, $R^2=0.90$
- หมายเหตุ: เน้น time-series ของ PM2.5 เป็นหลัก (มีการอ้างถึงความสำคัญของการเพิ่มข้อมูลอุตุนิยมวิทยาในอนาคต)
- งานร่วม: "Integrating quantile regression with ARIMA and ANN for interpretable and accurate PM2.5 forecasting in Hat Yai, Thailand", *Scientific Reports* (DOI: 10.1038/s41598-025-27294-1)

19. Lag-dependent Gaussian process (2024) — "Analyzing and forecasting air pollution concentration in the capital and Southern Thailand using a lag-dependent Gaussian process model", *Environmental Monitoring and Assessment*. DOI: 10.1007/s10661-024-13275-w

- พื้นที่: ภาคใต้ + กรุงเทพฯ ([Springer](#)) (ข้อมูลรายวันตั้งแต่ 1 ม.ค. 2020)
- โมเดล: LDGP (Bayesian non-parametric), AR-DNN, AR-RF, GB, KNN; ให้ confidence band ของค่าพยากรณ์

จ) ภาคอีสาน (ช่องว่างงานวิจัย)

- ยังไม่มีงานพยากรณ์ PM2.5 แบบ **multivariate ML/DL** ที่สร้างและฝึกเฉพาะเมืองในภาคอีสาน (ขอนแก่น นครราชสีมา อุบลราชธานี ฯลฯ)
- งานที่ครอบคลุมอีสาน "Air Pollution Forecasting in a Regional Context for Sustainable Management" (*Emerging Science Journal* 2024, ครอบคลุมขอนแก่น เลย นครราชสีมา

หนองคาย นครพนม อุบลราชธานี ปี 2021-2023) ใช้ **Generalized Pareto Distribution / Extreme Value Theory** ซึ่งเป็นวิธีสถิติ ไม่ใช่ **multivariate ML** — จึงไม่เข้าเกณฑ์

- Paluang et al. (2024, ข้อ 6) เป็นงานที่ใกล้เคียงที่สุด (MLP-ANN หลายตัวแปร) แต่ฝึกจากภาคเหนือแล้วเพียงนำไปประยุกต์กับอีสาน
- มีเบาะแสงานอุดรธานี (เทียบ 4 อัลกอริทึม, RMSE ต่ำสุด 2.945) ที่ถูกอ้างถึงมือสอง ควรตามหาต่อ

การเปรียบเทียบ univariate vs multivariate และชุดข้อมูลไทยเปิด

- งานกรุงเทพฯ (RF/GB/LSTM) และ Sabkam (2025) แสดงชัดว่า การเพิ่มปัจจัย (อุตุนิยมวิทยา มลพิษ จุดความร้อน) ช่วยเพิ่มความแม่นยำ (Sabkam ระบุจุดความร้อนช่วย ~20%); งานต่างประเทศ (Chengdu) ก็ยืนยันว่า multivariate เหนือกว่า univariate โดยเฉพาะเมื่อเพิ่มปัจจัยอุตุนิยมวิทยา
- ชุดข้อมูลไทยเปิดที่ใช้อยู่: PCD/Air4Thai (air4thai.pcd.go.th), Sensor for All (จุฬาฯ, sensorforall.eng.chula.ac.th — พยากรณ์ 3 วันล่วงหน้า), GISTDA PM2.5 (pm25.gistda.or.th), NRCT Air Quality Information Center (pm2_5.nrct.go.th) และกรมอุตุนิยมวิทยา (TMD)

Recommendations

1. พื้นที่ที่ไฟป่า/การเผาชีวมวลเป็นตัวขับเคลื่อนหลัก (ภาคเหนือ/อีสาน): รวมจุดความร้อน (MODIS/VIIRS FIRMS) แบบ lag หลายระยะทาง (100-700+ กม.) ตาม Sabkam (2025) และ Kawichai (2025) — เกณฑ์: ถ้าการเพิ่ม hotspot ยกกระดาน R^2 /ลด RMSE ได้ >10% ให้คงไว้เป็นปัจจัยหลัก
2. กรุงเทพฯ/ภาคกลาง: ใช้ gradient boosting/LightGBM กับ feature engineering (moving averages, cyclical encoding) และ AOD ดาวเทียม (Himawari-8/Fengyun-4A) + การใช้ที่ดินสำหรับ spatial coverage; GB ให้ผลดีเยี่ยม ($R^2 \approx 0.94$) ในข้อมูลกรุงเทพฯ
3. การพยากรณ์เชิงพื้นที่ทั่วประเทศ: พิจารณา spatiotemporal deep learning (SimVP/IAM4VP/ConvLSTM ensemble) กับข้อมูล Sensor for All + PCD; เหมาะเมื่อต้องการแผนที่พยากรณ์ทั้งประเทศ
4. เต็มช่องว่างภาคอีสาน (ลำดับความสำคัญสูง): สร้างงานพยากรณ์ multivariate เฉพาะเมืองอีสาน (ขอนแก่น นครราชสีมา อุบลฯ) โดยใช้ PCD/TMD + จุดความร้อน + AOD เพราะบริบทการเผา (เศษวัสดุเกษตร) ต่างจากภาคเหนือ (ไฟป่า) ทำให้โมเดลที่ฝึกจากภาคเหนือ underestimate
5. เกณฑ์เลือกโมเดล: ถ้าข้อมูลย้อนหลังยาว/ครบและมีมิติเชิงพื้นที่ ให้ลอง deep learning; ถ้าข้อมูลสั้นหรือเป็นตาราง ให้ tree-based (RF/GB/XGBoost/LightGBM) ซึ่งงานไทยส่วนใหญ่พบว่าให้ผลดีกว่าและฝึกเร็วกว่า

Caveats

- บางงาน (Wongrin 2023, Chumnaul 2025) เน้น time-series ของ PM2.5 เป็นหลักมากกว่าปัจจัยหลายตัวแปร — จัดเป็นงานเปรียบเทียบเชิงวิธี
- งานหลายชิ้น (Kawichai, Buaya, Paluang, Thongthammachart, งาน Greater Bangkok AOD) เป็น "estimation/nowcasting" เชิงพื้นที่/ย้อนหลัง ไม่ใช่การ "forecast" ล่วงหน้าอย่างแท้จริง — ควรแยกวัตถุประสงค์ให้ชัด
- ค่า metric เทียบข้ามงานไม่ได้ตรงๆ เพราะพื้นที่ ช่วงเวลา ความละเอียด (รายชั่วโมง/รายวัน) และหน่วย (บางงานเป็น normalized) ต่างกัน เช่น Paluang รายงาน RMSE=0.0282 (normalized)

ขณะที่งานอื่นเป็น $\mu\text{g}/\text{m}^3$

- งาน Sabkam ให้ $R^2=0.97$ สูงมาก ควรตรวจสอบวิธี validation (in-sample vs out-of-sample) ก่อนนำไปอ้างเป็น benchmark
- งาน "Bangkok 2020-2024" (ข้อ 8) และงาน ensemble (ข้อ 16) เป็นสิ่งพิมพ์ปี 2025-2026 ที่เพิ่งออก บางฉบับยังอยู่ในกระบวนการจัดเล่ม/หน้า